

Maya Gen İfade Verilerinde Periyodik Gen Keşfi

Çoklu Deney Entegrasyonu ve
Veri Sızıntısına Karşı Dayanıklı
Uçtan Uca Bir Makine
Öğrenmesi Çerçevesi

Emre Can

Danışman: Prof. Dr. Ayşe Yücel


Biyoinformatik Ana Bilim Dalı | 2026





Hücre Döngüsünün Moleküler Saati

Hücre büyümesi ve çoğalması, döngü boyunca periyodik olarak ifade edilen genlere bağlıdır. 1998'de Spellman ve arkadaşları, maya genomunda periyodik olarak düzenlenen yaklaşık 800 genlik bir Altın Standart referans kümesi tanımlamıştır.



Biyolojik Sinyal, Gürültülü Veri

Periyodik genler tüm genomun yalnızca %12.9'unu oluşturur. Mikrodizi zaman serileri ise gürültülü, eksik verili ve dengesizdir. Makine öğrenmesi bu engelleri aşmak için kullanılsa da, süreç içinde ciddi analitik riskler göz ardı edilmiştir.

Literatürdeki Üç Ölümcül Metodolojik Zafiyet

Geçmiş uygulamalar, sonuçların güvenilirliğini zedeleyen üç temel yapısal hata barındırmaktadır:



1. Veri Sızıntısı (Data Leakage)

Eşik (threshold) optimizasyonunun doğrudan test seti üzerinde yapılması. Modelin başarısı gerçek bir öğrenmeden ziyade yapay bir iyimserliğe dayanmaktadır.



2. Döngüsellik (Circularity)

Altın standart etiketin üretildiği istatistiksel yöntemlerin, özellik mühendisliğinde de birebir kullanılması. Model periyodikliği değil, etiketleme formülünü ezberlemektedir.



3. Tek Deney Bağımlılığı

Orijinal veri setinde 4 ayrı deney bulunmasına rağmen, sınıflandırmanın yalnızca tek bir senkronizasyon deneyine (CDC15) daraltılması.

Metodolojik Yeniden İnşa: Paradigma Değişimi

Boyut	Geçmiş Çalışmalar	Bu Tez
Veri Tabanı	Temizlenmiş alt küme (Geniş veri kaybı)	Filtrelenmemiş ham 6178 ORF (Sıfır Kayıp) ✓
Spektral Analiz	Hızlı Fourier Dönüşümü (Eksik veride çuvallar)	Lomb-Scargle Periyodogramı (Eşitsiz zamana duyarlı) ✓
Validasyon Mimarisi	Standart Train/Test (Sızıntı riski)	Kutu-Dışı Optimizasyon + Bağımsız Doğrulama ✓
Deney Kullanımı	Yalnızca CDC15 deneyi	4 Deneyin Tam Entegrasyonu + Çapraz Tutarlılık ✓

Veri Mimarisi: 4 Deneyin Tamamı

Spellman veri setindeki 4 senkronizasyon deneyi, filtreleme yapılmadan sisteme dâhil edilmiştir.

Alfa Faktörü



🕒 18 zaman noktası | % %3.67 eksik veri

CDC15



🕒 24 zaman noktası | % %9.95 eksik veri

CDC28



🕒 17 zaman noktası | % %6.07 eksik veri

Elutriation



🕒 14 zaman noktası | % %2.04 eksik veri

6178 Genlik Ham Genom: 0 Gen Kaybı

Hiçbir gen veya zaman noktası baştan silinmemiştir. Eksik veriler algoritmik modelleme ile ele alınmış, birleşim sonrası gen kaybı sıfıra indirilmiştir.

Sinyali Yakalamak: 68 Öznitelikli Yeni Matris


1. Temel İstatistik

Ortalama, standart sapma, tepe noktası sayısı ve otokorelasyon hesaplamaları.



2. Spektral İnovasyon: Lomb-Scargle

Eksik verileri silmek yerine, eşit olmayan zaman serilerinde periyodikliği modelleyen Lomb-Scargle Periyodogramı kullanılmıştır.




3. Büyük Yenilik: Çapraz Deney Tutarlılığı

Bir genin periyodik olması için bağımsız deneylerde aynı sinyali vermesi gerekir. Alfa, CDC15 ve CDC28 arasındaki tutarlılık ölçülerek yepyeni çapraz-deney öznitelikleri türetilmiştir.



Zırhlı Boru Hattı: Sızıntıya Geçit Yok



Kutu-Dışı (Out-of-fold) Değerlendirme


Bütün karar mekanizmaları, model seçimi ve eşik taramaları yalnızca K-Fold ile elde edilen kutu-dışı eğitim seti olasılıkları üzerinden yapılmıştır.

Sızıntısız Test

Test seti, sadece en sonda nihai performansı ölçmek için 1 kez kullanılmıştır. Boru hattı, test setini nihai adıma kadar tamamen kilitli tutar.


Modellerin Savaşı ve Performans

Doğrusal olmayan ilişkileri yakalayan Tree-Boosting algoritmaları, klasik istatistikleri ve doğrusal modelleri açık ara geride bırakmıştır.



Eşik Optimizasyonu: Metodolojinin Zaferi

Eşik taraması sadece kutu-dışı (out-of-fold) tahminlerde yapılmıştır. Test setindeki F1 skorunun eğitim seti skoruna bu kadar yakın olması, genellenebilirliğin kanıtıdır.



Test Seti Karşılaştırması


Varsayılan Eşik (0.50):	F1(M) 0.8871
Optimize Eşik (0.48):	F1(M) 0.8878

Fark Yalnızca: 0.0007

Bu önemsiz fark, modelimizin aşırı öğrenmediğinin ve doğru metodolojinin yapay başarı iddialarını nasıl çürüttüğünün kesin kanıtıdır.

Model Neyi Öğrendi? (SHAP Analizi)

Modelin karar mekanizması incelendiğinde, bizzat bu tezde türetilen Çapraz-Deney Tutarlılık öz niteliklerinin en önemli 10 özelliğin 2. ve 3. sırasına yerleştiği görülmüştür.




Gerçek Sinyal Tutarlılıktadır

Periyodik genlerin %73.4'ü çoklu deneylerde yüksek otokorelasyon gösterirken, periyodik olmayanlarda bu oran %19'da kalmıştır.

Model ezberlememiş, deneyler arası tutarlılığı keşfetmiştir.

Nihai Sınav: Elutriation ile Bağımsız Doğrulama

Altın standart etiket (800 gen); Alfa, CDC15 ve CDC28 kullanılarak üretilmiştir.
Elutriation deneyi bu süreçte hiç katılmamıştır.



Elutriation Deneyi

Döngüsellik Testi

Eğer model sadece etiketleme formülünü ezberleseydi, etikete katılmayan Elutriation verisinde çuvallaması gerekirdi.

Sadece ELU Modeli:
AUC 0.6455

Tam Model (4 Deney):
AUC 0.9707




Sonuç: Yüksek başarı etiket ezberlemekten değil, çoklu deneylerin sağladığı sinyal entegrasyonundan gelmektedir.

Keşif: Yapay Zekanın Yeni Gen Adayları

Modelin metodolojik zırhı kanıtlandıktan sonra, altın standart dışındaki **5378** gene uygulanmıştır.

Model, **≥ 0.80** olasılıkla periyodik olduğuna inandığı **16** yepyeni gen tespit etmiştir.



Öne Çıkan Keşifler:

SPS100 & SPS1

Spor paketlenmesi ve spor duvarı olgunlaşması.

DPM1 & RHO1

Hücre duvarı regülasyonu ve sentezi.

YFL068W & YDL009C

İşlevi henüz bilinmeyen (novel) biyolojik aktörler.

Biyolojik Doğrulama (GO Zenginleştirme)

Bulunan 16 gen istatistiksel birer anomali midir, yoksa gerçek bir biyolojik ağın parçası mı?



Bu işlevsel ağ, istatistiksel olarak anlamlı biçimde zenginleşmiştir ($p_{adj} = 0.0189$).

Hücre/spor duvarı sentezi, maya literatüründe bilinen faz aktiviteleriyle kusursuz bir uyum içindedir. Makine öğrenmesi, salt veri üzerinden hücresel bir gerçeği yakalamıştır.

Sentez ve Gelecek Vizyonu



Tezin Temel Kazanımları:

- 1. **Veri Sızıntısına Son:** Kutu-dışı değerlendirme ile sızıntı sıfırlanmış, yapay başarılar engellenmiştir.
- 2. **Çapraz-Deneyin Gücü:** Lomb-Scargle ve çoklu deney özellikleri ile sınıflandırma performansı maksimize edilmiştir.
- 3. **Biyolojik Kanıt:** Döngüsellik hipotezi çürütülmüş, hücre duvarı sentezine ait yeni genler literatüre kazandırılmıştır.



Gelecek Ufku:

- Bağımsız altın-standart listelerle dış doğrulama.
- Ham zaman serisini doğrudan işleyecek 1D-CNN mimarileri.
- Keşfedilen yeni adayların qPCR ile laboratuvarıda validasyonu.